

D_CORTEX v2.0-alpha

Raport științific de dezvoltare progresivă

Document tehnico-științific bazat exclusiv pe logurile experimentale și pe iterațiile arhitecturale furnizate în conversație.

Obiectul raportului	Formalizarea, cronologia și evaluarea experimentală a unei arhitecturi de memorie explicită, persistentă și updatabilă pentru modele de limbaj.
Baza factuală	Toate concluziile sunt derivate din logurile de antrenare, benchmark-urile și diagnosticele furnizate de utilizator în această conversație.
Statutul actual	B1 trecut pe criteriile definite; sistemul funcționează pe sarcini structurale complexe, însă nu este încă validat ca memorie universală sau ca integrare completă într-un LLM mare, deschis și naturalistic.
Scopul documentului	Să servească drept raport academic de progres, document de arhivă experimentală și bază pentru următoarele faze de integrare și generalizare.

Notă metodologică: raportul nu pretinde validare externă independentă. El documentează riguros rezultatele obținute în regim intern de dezvoltare, pe baza configurațiilor, checkpoint-urilor și suite-urilor de test prezentate în loguri.

Rezumat executiv

Acest raport sintetizează evoluția unei arhitecturi de memorie explicită pentru modele de limbaj, dezvoltată iterativ de la variante în care memoria era decorativă sau colapsa sub presiunea loss-ului de limbaj, către o configurație în care memoria devine operațională, adresabilă și funcțional relevantă pentru emisia răspunsului. Traseul experimental a trecut prin etape de separare dual-agent, diagnoză a contaminării cross-batch, identificarea colapsului indus de un singur slot per bancă, introducerea unui curriculum structural cu adevăr de bază programatic, corectarea canalului de adresare și, în final, validarea unui regim de "lexical value binding" și a unor episoade complexe cu update-uri și distractori.

La checkpoint-ul final al etapei B1 (v11), sistemul a atins 94,4% pe episoade simple, 100,0% pe update-uri și 99,2% pe distractori, cu degradare graduală până la 72,4% în scenariul de 15 fapte, fără leak pe lanțuri de update până la lungime 8 și cu generalizare bună pe entități rare din aceeași distribuție. Aceste rezultate nu demonstrează încă o memorie universală generală, dar demonstrează experimental că un model de limbaj poate fi extins cu un strat de memorie explicită persistentă, actualizabilă și adresabilă, distinct atât de weights, cât și de contextul local.

Concluzii-cheie

- Arhitectura demonstrează memorie de obiecte (object-centric memory) și nu doar stocare difuză de context.
- Mecanismul de update este stabil: 100% pe lanțuri de update 1 / 2 / 4 / 8, cu leak 0% către valori vechi sau intermediare.
- Rezistența la distractori este foarte ridicată (~99%), semn că adresarea nu se prăbușește în prezența concurenței structurale.
- Scalarea până aproape de capacitatea working memory (16 sloturi) produce degradare graduală, nu colaps.
- Generalizarea cross-schema pe clase neantrenate rămâne limitată; aici se află frontul următor de cercetare.

Cuprins orientativ

- 1. Obiectiv științific și ipoteză de lucru
- 2. Configurația experimentală și metodologia de evaluare
- 3. Cronologia dezvoltării: de la v2 la v11
- 4. Rezultate cantitative consolidate
- 5. Ce demonstrează sistemul și ce nu demonstrează încă
- 6. Valoarea de inovație și poziționarea conceptuală
- 7. Limite actuale și pașii următori

1. Obiectiv științific și ipoteză de lucru

Obiectivul programului D_CORTEX a fost construirea unei arhitecturi în care memoria explicită să nu fie echivalentă nici cu contextul promptului, nici cu cunoașterea parametrică stocată în weights. Ipoteza de lucru a fost că un model de limbaj poate fi extins cu un strat explicit de memorie de obiecte, capabil să stocheze, să selecteze, să actualizeze și să emită conținut pe baza unor entități distincte, într-un mod cauzal și persistent.

În termeni funcționali, ținta nu a fost doar „să răspundă corect”, ci să demonstreze separarea dintre trei straturi operaționale:

- weights parametrici: regularități generale și limbaj de fond;
- context local: fluxul secvențial imediat al inputului curent;
- memory explicită: stare persistentă și actualizabilă asociată unor obiecte sau entități specifice.

Succesul unui astfel de sistem cere simultan patru proprietăți: (i) adresare corectă a obiectului țintă, (ii) separare între obiecte concurente, (iii) update fără contaminare retrospectivă, și (iv) legătură cauzală între valoarea recuperată și răspunsul emis. O bună parte din istoria experimentală a proiectului constă tocmai în izolarea patologiilor care împiedicau una sau mai multe dintre aceste patru proprietăți.

2. Configurația experimentală și metodologia de evaluare

Toate rulările documentate în această sinteză au folosit hardware de tip NVIDIA A100-SXM4-40GB, cu antrenare în bfloat16 / TF32, fără GradScaler. Pentru regularizarea limbajului s-a folosit TinyStories (80.000.000 tokeni train; 4.765.918 tokeni validation), iar pentru partea de memorie s-au generat episoade structurale sintetice care instanțiau fapte, întrebări, update-uri și distractori.

Componentă	Detalii sintetice
Backbone experimental	Dual-agent: encoder (scriere în memorie) + decoder (citire și emisie).
Infrastructură semantică comună	Embedding-uri partajate + query/address encoder comun pentru chei și query-uri.
Memorie explicită	Bănci de memorie pentru state, episode/object, conflict, archive, working; în fazele de validare lexicală scrierile au fost forțate într-un singur pool de retrieval pentru validarea de principiu.
Tipuri de episoade	simple retrieval, update/contradiction, distractors, scaling by fact count, rare-target tests, cross-schema tests.
Metrici principale	Top-1 accuracy, Top-3 accuracy, MRR, mean rank, mean slots / occupancy, leak pe chain-uri de update,

	val_loss pe TinyStories.
--	--------------------------

Evaluarea a fost organizată în două registre complementare. Primul a urmărit dacă subsistemul de memorie își face treaba internă: scrie obiecte distincte, selectează slotul corect, actualizează aceleași entități și rezistă la distractori. Al doilea a urmărit dacă această memorie influențează efectiv emisia de răspuns și dacă rămâne compatibilă cu un flux LM obișnuit. Această distincție este critică, deoarece un sistem poate avea retrieval intern bun și totuși să nu folosească memoria în generarea tokenului final.

3. Cronologia dezvoltării arhitecturale

Traectoria de dezvoltare poate fi împărțită în trei faze mari: (A) descoperirea patologiilor structurale, (B) stabilizarea adresării și a scrierii de obiecte, și (C) conectarea retrieval-ului la emisia lexicală și validarea pe episoade complexe.

v2-v5: memorie decorativă sau colapsată

Backbone-ul putea satisface loss-ul de limbaj fără memorie; scrierea și citirea nu deveneau inevitabile. Cheile colapsau, ocupanța rămânea minimă, iar benchmark-urile memory-vs-no-memory erau practic la 0% diferență. Diagnosticul central: dacă răspunsul poate fi rezolvat din context sau din priorul backbone-ului, SGD preferă lanțul scurt și omoară memoria.

v6: separare dual-agent

Separarea dintre encoder/writer și decoder/reader a eliminat shortcut-ul trivial prin aceleași weights. Totuși, gradientul către encoder rămânea slab, iar sistemul nu selecta efectiv între obiecte; multe variante au produs 0% pe benchmark-urile de memorie chiar și după introducerea overlay-ului.

v6 overlay și B=1 serial

S-a identificat contaminarea cross-batch și faptul că același pool de memorie era corupt de exemple simultane. Trecerea la episoade seriale (B=1) a eliminat contaminarea, dar a scos la iveală altă problemă structurală: dacă fiecare episod scrie doar un singur fapt, atunci softmax-ul pe un singur slot are gradient zero pentru query engine.

v8: curriculum structural cu adevăr de bază programatic

Introducerea episoadelor multi-fact (3-5 fapte) și a loss-urilor L_{sel} , L_{sep_neg} , L_{sep_pos} și L_{occ} a rezolvat problema selecției și a scrierii de obiecte distincte. Sistemul a ajuns să aloce aproape un slot per entitate și să obțină retrieval intern aproape perfect, dar încă nu transforma valoarea recuperată în răspunsul lexical corect.

v9: aux head, cycle și LM mix

Această fază a demonstrat clar o disociere între retrieval intern și emisie. Chiar când selecția cheii era foarte bună, top-1 pe răspuns rămânea aproape aleator în spațiul culorilor, semn că legătura value → answer nu era suficient de constrânsă.

v10: lexical value binding + single retrieval pool

Au fost găsite trei bug-uri critice: proiecții pe zero care injectau zgomot prin bias, difuzie excesivă a atenției și, mai ales, distribuirea faptelor în bănci diferite unde fiecare bancă cu un singur slot producea atenție 1.0 indiferent de query. Forțarea scrierii într-un singur pool („working”), combinată cu lexical binding al valorii, a validat de principiu canalul complet stocare → selecție → emisie. La finalul v10, 4-fact validation a trecut pragul de 90%.

v11: episoade complexe, warm-start din v10, obiectiv B1

Pe warm-start din v10, sistemul a transferat imediat pe simple, update și distractor episodes. Update-urile au atins 100% și au rămas perfecte până la lanțuri lungi; distractorii au rămas aproape de plafon; simple retrieval s-a stabilizat între 94% și 96%. Aceasta este prima fază în care se poate vorbi despre B1 trecut în mod real.

4. Rezultate cantitative consolidate

Rezultatele de mai jos sintetizează punctele de referință care schimbă statutul proiectului din ipoteză arhitecturală în demonstrație funcțională limitată, dar reală.

4.1. Repere intermediare relevante

Etapă	Observație dominantă	Rezultat numeric reprezentativ	Interpretare
v6 fără corecții structurale	Dual-agent, dar fără memorie operațională	Suite A/B/C: 0% delta; occupancy $\approx$ 0-1 slot	Separarea agenților nu este suficientă fără adresare și selecție efectivă.
v8 structural curriculum	Selecția cheii și ocupația devin corecte	retr_acc intern $\sim$ 97%; mean_occ $\approx$ 3.7/4	Retrieval-ul intern funcționează, dar emisia lexicală nu este încă ancorată.
v10 lexical binding	Canalul complet memorie → answer este validat	struct_acc_4 $\approx$ 92%; struct_acc_5 $\approx$ 94%	Dovadă de principiu că valoarea recuperată poate produce tokenul corect.
v11 Objective B1	Transfer pe episoade complexe	simple 94.4%; update 100%; distractor 99.2%	B1 trecut pe criteriile definite.

4.2. Evaluarea finală B1 (checkpoint v11, step 4000)

Categorie episod	Acuratețe finală	Prag definit	Verdict
Simple	94,4%	>85%	PASS
Update	100,0%	>75%	PASS
Distractor	99,2%	>75%	PASS

4.3. Test de scalare la număr de fapte

n_facts	Simple	Update	Distractor
3	97,5%	100,0%	98,5%
5	92,5%	100,0%	99,0%
7	87,0%	100,0%	98,5%
10	86,5%	100,0%	100,0%
15*	72,4%	100,0%	93,6%

* valoarea pentru 15 fapte provine din suita B1.1 de validare la capacitate; ea arată degradare graduală aproape de limita working memory, fără colaps.

4.4. Validări suplimentare B1.1

- Lanțuri de update cu lungime 1 / 2 / 4 / 8: 100,0% în toate cazurile.
- Leak test la chain=3: 0/300 spre valoarea inițială; 0/300 spre valorile intermediare.
- Rare-only entities: 100,0%; rare target + 4 distractori frecvenți: 95,3%.
- Cross-schema pe clase antrenate (animal + fantasy): 91,8%.
- Cross-schema pe patru clase, dintre care unele neantrenate explicit: 70,8%.

5. Interpretare științifică: ce demonstrează sistemul

Pe baza rezultatelor consolidate, se pot formula cu rigoare următoarele afirmații.

5.1. Memoria este operațională, nu ornamentală

Memoria nu mai este un container inert. Sistemul scrie obiecte distincte, selectează obiectul corect, actualizează aceeași entitate și răspunde pe baza valorii recuperate. Cu alte cuvinte, retrieval-ul și emisia nu mai sunt paralele și deconectate, ci cuplate cauzal într-un regim de funcționare reproductibil.

5.2. A fost demonstrată o memorie centrată pe obiecte (object-centric memory)

Faptele de tipul „cat = red”, „dog = blue”, „dragon = green” nu mai sunt absorbite într-un nor contextual global, ci sunt reprezentate ca obiecte separate, adresabile individual. Această proprietate este esențială pentru orice sistem care vizează persistență și actualizare reală a stării.

5.3. Update-ul este stabil și curat

Rezultatele de 100% pe chain-uri de update, plus absența completă a leak-ului, arată că sistemul nu doar stochează noi valori, ci rescrie efectiv starea aceleiași entități fără a reactiva reziduuri istorice.

5.4. Rezistența la distractori este excepțională în distribuția antrenată

Acuratețea ~99% pe distractor episodes arată că adresarea nu este doar vag similară, ci suficient de precisă pentru a evita entitățile concurente chiar în episoade aglomerate.

5.5. Memoria se comportă ca al treilea strat funcțional al modelului

Rezultatele susțin distincția dintre weights parametrice, context secvențial și memorie explicită persistentă. Acesta este punctul de inovație cel mai puternic al întregului program: memoria nu mai este tratată ca simplă extensie de context și nici ca simplă cunoaștere absorbită în weights.

6. Ce nu demonstrează încă sistemul

Pentru a păstra rigoarea academică, trebuie delimitat explicit ce a fost demonstrat de ceea ce rămâne încă deschis.

- Nu a fost demonstrată încă o memorie generală universală, independentă de distribuția structurală folosită în antrenare.
- Nu a fost demonstrată încă integrarea completă într-un LLM open-source mare, expus la limbaj natural deschis, parafraze și texte lungi nestructurate.
- Nu a fost demonstrată autonomie completă multi-bank în regim liber; în validarea de principiu și în B1, forțarea într-un singur retrieval pool a fost o alegere experimentală justificată, dar rămâne o constrângere de laborator.
- Scăderea la 70,8% pe cross-schema cu clase neantrenate arată că mecanismul este valid, dar acoperirea semantică și compozițională nu este încă generală.

Aceste rezerve nu anulează rezultatul principal. Ele definesc corect frontiera dintre „mecanism demonstrat” și „arhitectură universalizată”.

7. Valoarea de inovație și poziționarea conceptuală

Valoarea de inovație a sistemului nu constă doar în îmbunătățirea punctuală a performanței pe un benchmark sintetic, ci în demonstrarea unui regim operațional nou: acela în care memoria explicită poate exista ca strat distinct de funcționare în interiorul unui sistem de limbaj.

Mai exact, inovația poate fi formulată astfel:

Un model de limbaj poate fi extins cu o memorie explicită persistentă, adresabilă și actualizabilă, care susține selecție robustă de obiecte, update fără leak și emisie lexicală

ghidată de valoarea recuperată, fără colaps imediat la scalare și fără prăbușire în prezența distractorilor.

Din punct de vedere epistemic, aceasta mută discuția de la întrebarea „este posibil?” la întrebările „cât de general este?” și „cum se integrează într-un LLM real?”. Din punct de vedere ingineresc, aceasta furnizează o bază concretă pentru dezvoltarea unei memorii care nu cere reantrenarea întregii biblioteci de weights pentru fiecare nouă bucată de cunoaștere, ci permite adăugare, rescriere și interogare directă de stare.

8. Pașii următori recomandați

După trecerea B1, următorul obiectiv nu mai este validarea posibilității de bază, ci generalizarea controlată și integrarea într-un model real. Următoarele direcții sunt cele mai bine motivate de datele actuale.

Direcție	Rațiune experimentală	Criteriu de succes
B2: relaxarea constrângerilor de laborator	Trebuie redusă dependența de <code>force_bank</code> și de lexical binding rigid pentru a verifica dacă mecanismul rămâne stabil într-o formă mai generală.	Performanță apropiată de B1 fără prăbușire a selecției sau a emisiei.
B3: held-out real și distribuție shift	Rare entities nu sunt același lucru cu entități excluse total din training.	Păstrarea unei acurateți ridicate pe entități, forme și combinații nevăzute.
Integrare într-un LLM open-source	Acesta este testul mare: memoria trebuie transplantată într-un backbone naturalist și evaluată pe limbaj real.	Retrieval stabil și util în contexte naturale, cu compatibilitate LM acceptabilă.
Episoade naturale și parafraze	Trebuie depășită structura sintetică curată.	Răspunsuri corecte la întrebări formulate variat, inclusiv descrieri indirecte și parafraze.
Multi-bank autonomy	Rolurile multiple ale băncilor trebuie validate ca funcții reale, nu doar ca posibilitate arhitecturală.	Îmbunătățiri măsurabile atunci când state / conflict / archive / working sunt lăsate să specializeze liber.

Concluzie

În stadiul actual, proiectul D_CORTEX a depășit faza de speculație arhitecturală. Rezultatele arată că mecanismul propus de memorie explicită este executabil, stabilizabil și reproductibil pe sarcini structurale non-triviale. B1 este trecut cu marjă mare pe criteriile definite, update-ul este practic perfect, rezistența la distractori este excepțională, iar degradarea la scalare rămâne

graduală și controlată. Aceasta justifică trecerea proiectului din faza de demonstrație de principiu în faza de generalizare și integrare.

Formularea cea mai exactă a contribuției este următoarea: a fost demonstrat experimental că un sistem de limbaj poate opera cu o memorie explicită persistentă și actualizabilă, distinctă atât de context, cât și de weights, capabilă să susțină stocare, selecție și rescriere de obiecte fără leak și fără colaps imediat la concurență sau scalare. Din acest punct, întrebarea critică nu mai este dacă mecanismul poate exista, ci cât de general poate deveni.

Anexă A. Setul minim de rezultate-cheie folosit în acest raport

Bloc experimental	Rezultate-cheie	Funcție în argumentul științific
v6 / v6 overlay	benchmark-uri cu delta $\approx 0\%$; gradient encoder inițial dar colaps ulterior	Au arătat că separarea agenților fără adresare și selecție corectă nu rezolvă problema.
v8 structural curriculum	retrieval intern aproape perfect; mean_occ $\sim$ nr. entități	A demonstrat că selecția și ocupanța pot fi învățate programatic.
v10 lexical binding	4-fact $>90\%$; 10-fact $\sim 78,7\%$	A validat de principiu legătura retrieval $\rightarrow$ emission.
v11 B1 final	simple 94,4%; update 100%; distractor 99,2%	A demonstrat funcționarea pe episoade complexe.
B1.1 validation	15 facts simple 72,4%; update chains 100%; rare target 95,3%; cross-trained cluster 91,8%	A delimitat puterea și limitele actuale ale sistemului.

Anexă B. Declarație de utilizare responsabilă a concluziilor

Acest document poate fi folosit ca raport intern de progres, anexă tehnică pentru documentarea cercetării, bază de discuție pentru planificarea fazelor următoare și schelet pentru o versiune viitoare destinată publicării sau brevetării. Nu trebuie însă confundat cu o demonstrație finală de memorie generală universală sau cu o validare pe scară largă în condiții complet naturale. Aceste extensii rămân obiective ale fazelor următoare.